

Aprendizado de Máquina – IMD1101

Aula 17 – Naive Bayes

Teorema de Bayes

- ❑ **Thomas Bayes** foi um matemático inglês.



Teorema de Bayes

- ❑ Muitas vezes, uma informação é apresentada na forma de **probabilidade condicional**.
- ❑ Exemplo:
 - ❖ Qual a **probabilidade** de um evento ocorrer dada uma condição?
 - A probabilidade de um evento **B** ocorrer, sabendo qual será o resultado de um evento **A**.
- ❑ Esse tipo de problema é tratado usando o **Teorema de Bayes**.

Teorema de Bayes

□ Probabilidade de um evento H dada a evidência E :

$$Pr[H|E] = \frac{Pr[E|H]Pr[H]}{Pr[E]}$$

□ onde:

❖ Probabilidade a priori de H : **$Pr[H]$**

- Probabilidade do evento antes da evidência ser vista.

❖ Probabilidade a posteriori H : **$Pr[H/E]$**

- Probabilidade do evento após da evidência ser vista.

Teorema de Bayes

❑ Exemplo:

- ❖ Um médico sabe que a meningite causa torcicolo em 50% dos casos.
 - Probabilidade **a priori** de qualquer paciente ter meningite: $1/50.000$;
 - Probabilidade **a priori** de qualquer paciente ter rigidez de nuca: $1/20$.
- ❖ Se um paciente tem rigidez de nuca (evidência), qual será a probabilidade **a posteriori** de ele ter **meningite**?

Teorema de Bayes

□ Exemplo:

❖ Dado:

- M: meningite;
- R: rigidez no pescoço.

$$P(M|R) = \frac{P(R|M)P(M)}{P(R)} = \frac{0,5 * 1/50000}{1/20} \\ = 0,0002$$

Teorema de Bayes

□ Exemplo:

❖ Dado:

- M: meningite;
- R: rigidez no pescoço.

$$P(M|R) = \frac{P(R|M)P(M)}{P(R)} = \frac{0,5 * 1/50000}{1/20} = 0,0002$$

Ou seja, A probabilidade de uma pessoa ter meningite dado que ela está com dor no pescoço é 0,02%.

Naive Bayes

□ Pima Indians Diabetes Database (Discretized)

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
Normal	Low	High	Poor	Low	Obesity	Low_Risk	Adult	tested_positive
Low	Very_Low	High	Average	Low	Overweight	Low_Risk	Adult	tested_negative
High	Very_High	High	Good	Low	Normal	Low_Risk	Adult	tested_positive
Low	Very_Low	High	Average	Low	Overweight	Low_Risk	Youth	tested_negative
Low	Low	Normal	Poor	Low	Obesity	High_Risk	Adult	tested_positive
Normal	High	High	Good	Low	Overweight	Low_Risk	Adult	tested_negative
Low	Very_Low	Normal	Poor	Low	Obesity	Low_Risk	Youth	tested_positive
High	High	Low	Good	Low	Obesity	Low_Risk	Adult	tested_negative
Low	Very_High	High	Poor	Normal	Obesity	Low_Risk	Senior	tested_positive
Normal	High	High	Good	Low	Obesity	Low_Risk	Adult	tested_negative
High	Very_High	High	Good	Low	Obesity	Low_Risk	Adult	tested_positive
High	Low	High	Good	Low	Overweight	Normal_Risk	Senior	tested_negative
Low	Very_High	Normal	Average	High	Obesity	Low_Risk	Senior	tested_positive
Normal	Low	High	Average	Low	Overweight	Low_Risk	Senior	tested_positive
High	High	Low	Good	Low	Overweight	Low_Risk	Adult	tested_positive
Low	High	High	Poor	Low	Obesity	Low_Risk	Adult	tested_positive
High	High	High	Good	Low	Overweight	Low_Risk	Adult	tested_positive
Low	High	Normal	Poor	Low	Obesity	Low_Risk	Adult	tested_negative
Low	High	High	Average	Low	Obesity	Low_Risk	Adult	tested_positive
Low	Low	High	Poor	Low	Obesity	Low_Risk	Adult	tested_negative

Naive Bayes

- ❑ Aprendizado: qual a probabilidade da **classe** dada uma instância?
 - ❖ Evidência E = uma instância;
 - ❖ Evento H = valor da classe para a instância (Diagnóstico = **positive**, Diagnóstico = **negative**).
- ❑ Suposição Naive Bayes: evidência pode ser dividida em **partes independentes** (i.e., os atributos das instâncias são independentes).

Naive Bayes

□ Probabilidades para o atributo Pregnant:



Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
Low	Very_Low	High	Average	Low	Overweight	Low_Risk	Adult	tested_negative
Low	Very_Low	High	Average	Low	Overweight	Low_Risk	Youth	tested_negative
Low	Low	Normal	Poor	Low	Obesity	High_Risk	Adult	tested_positive
Low	Very_Low	Normal	Poor	Low	Obesity	Low_Risk	Youth	tested_positive
Low	Very_High	High	Poor	Normal	Obesity	Low_Risk	Senior	tested_positive
Low	Very_High	Normal	Average	High	Obesity	Low_Risk	Senior	tested_positive
Low	High	High	Poor	Low	Obesity	Low_Risk	Adult	tested_positive
Low	High	Normal	Poor	Low	Obesity	Low_Risk	Adult	tested_negative
Low	High	High	Average	Low	Obesity	Low_Risk	Adult	tested_positive
Low	Low	High	Poor	Low	Obesity	Low_Risk	Adult	tested_negative

Naive Bayes

□ Probabilidades para o atributo Pregnant:



Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
Normal	Low	High	Poor	Low	Obesity	Low_Risk	Adult	tested_positive
Normal	High	High	Good	Low	Overweight	Low_Risk	Adult	tested_negative
Normal	High	High	Good	Low	Obesity	Low_Risk	Adult	tested_negative
Normal	Low	High	Average	Low	Overweight	Low_Risk	Senior	tested_positive

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
High	Very_High	High	Good	Low	Normal	Low_Risk	Adult	tested_positive
High	High	Low	Good	Low	Obesity	Low_Risk	Adult	tested_negative
High	Very_High	High	Good	Low	Obesity	Low_Risk	Adult	tested_positive
High	Low	High	Good	Low	Overweight	Normal_Risk	Senior	tested_negative
High	High	Low	Good	Low	Overweight	Low_Risk	Adult	tested_positive
High	High	High	Good	Low	Overweight	Low_Risk	Adult	tested_positive

Naive Bayes

□ Probabilidades para o Conjunto:

Pregnant			Plasma			BloodPressure			Skin		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	6	4	Very_Low	1	2	Low	1	1	Poor	5	2
Normal	2	2	Low	3	2	Normal	3	1	Average	3	2
High	4	2	High	4	4	High	8	6	Good	4	4
-			Very_High	4	0	-			-		
Insulin			BodyMass			Pedigree			Age		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	10	8	Normal	1	0	Low_R	11	7	Youth	1	1
Normal	1	0	Overweight	3	4	Normal_R	0	1	Adult	8	6
High	1	0	Obesity	8	4	High_R	1	0	Senior	3	1

Diagnóstico		
-	Positive	Negative
	12	8

Naive Bayes

□ Probabilidades para o Conjunto:

Pregnant			Plasma			BloodPressure			Skin		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	6	4	Very_Low	1	2	Low	1	1	Poor	5	2
Normal	2	2	Low	3	2	Normal	3	1	Average	3	2
High	4	2	High	4	4	High	8	6	Good	4	4
-	-	-	Very_High	4	0	-	-	-	-	-	-
Insulin			BodyMass			Pedigree			Age		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	10	8	Normal	1	0	Low_R	11	7	Youth	1	1
Normal	1	0	Overweight	3	4	Normal_R	0	1	Adult	8	6
High	1	0	Obesity	8	4	High_R	1	0	Senior	3	1

Diagnóstico		
-	Positive	Negative
	12	8

Naive Bayes

□ Probabilidades para o Conjunto:

Pregnant			Plasma			BloodPressure			Skin		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	6/12	4/8	Very_Low	1/12	2/8	Low	1/12	1/8	Poor	5/12	2/8
Normal	2/12	2/8	Low	3/12	2/8	Normal	3/12	1/8	Average	3/12	2/8
High	4/12	2/8	High	4/12	4/8	High	8/12	6/8	Good	4/12	4/8
-			Very_High	4/12	0	-			-		
Insulin			BodyMass			Pedigree			Age		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	10/12	8/8	Normal	1/12	0	Low_R	11/12	7/8	Youth	1/12	1/8
Normal	1/12	0	Overweight	3/12	4/8	Normal_R	0	1/8	Adult	8/12	6/8
High	1/12	0	Obesity	8/12	4/8	High_R	1/12	0	Senior	3/12	1/8

Diagnóstico		
-	Positive	Negative
	12/20	8/20

Naive Bayes

□ Probabilidades para o Conjunto:

Pregnant			Plasma			BloodPressure			Skin		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	6/12	4/8	Very_Low	1/12	2/8	Low	1/12	1/8	Poor	5/12	2/8
Normal	2/12	2/8	Low	3/12	2/8	Normal	3/12	1/8	Average	3/12	2/8
High	4/12	2/8	High	4/12	4/8	High	8/12	6/8	Good	4/12	4/8
-			Very_High	4/12	0	-			-		
Insulin			BodyMass			Pedigree			Age		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
Low	10/12	8/8	Normal	1/12	0	Low_R	11/12	7/8	Youth	1/12	1/8
Normal	1/12	0	Overweight	3/12	4/8	Normal_R	0	1/8	Adult	8/12	6/8
High	1/12	0	Obesity	8/12	4/8	High_R	1/12	0	Senior	3/12	1/8

Diagnóstico		
-	Positive	Negative
	12/20	8/20

Naive Bayes

□ Para uma nova instância:

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
High	High	High	Poor	Low	Obesity	Low_Risk	Adult	?

Naive Bayes

□ Para uma nova instância:

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
High	High	High	Poor	Low	Obesity	Low_Risk	Adult	?



Naive Bayes

□ Resolução:

$$P(diag = pos | E) = \frac{P(E | diag = pos) * P(diag = pos)}{P(E)}$$

Naive Bayes

□ Para *Diagnóstico = positive*:

$$P(\text{Pregnant} = \text{High} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 4/12$$

$$P(\text{Plasma} = \text{High} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 4/12$$

$$P(\text{BloodPressure} = \text{High} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 8/12$$

$$P(\text{Skin} = \text{Poor} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 5/12$$

$$P(\text{Insulin} = \text{Low} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 10/12$$

$$P(\text{BodyMass} = \text{Obesity} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 8/12$$

$$P(\text{Pedigree} = \text{Low_Risk} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 11/12$$

$$P(\text{Age} = \text{Adult} \mid \text{diagnóstico} = \text{positive}) \Rightarrow 8/12$$

$$P(\text{Diagnóstico} = \text{positive}) \Rightarrow 12/20$$

$$\Rightarrow P(E \mid \text{diagnóstico} = \text{positive}) * P(\text{diagnóstico} = \text{positive})$$

$$\Rightarrow (4/12)(4/12)(8/12)(5/12)(10/12)(8/12)(11/12)(8/12)(12/20)$$

$$\Rightarrow \mathbf{0,006287}$$

Naive Bayes

□ Para *Diagnóstico = negative*:

$$P(\text{Pregnant} = \text{High} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 2/8$$

$$P(\text{Plasma} = \text{High} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 4/8$$

$$P(\text{BloodPressure} = \text{High} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 6/8$$

$$P(\text{Skin} = \text{Poor} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 2/8$$

$$P(\text{Insulin} = \text{Low} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 8/8$$

$$P(\text{BodyMass} = \text{Obesity} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 4/8$$

$$P(\text{Pedigree} = \text{Low_Risk} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 7/8$$

$$P(\text{Age} = \text{Adult} \mid \text{diagnóstico} = \text{negative}) \Rightarrow 6/8$$

$$P(\text{Diagnóstico} = \text{negative}) \Rightarrow 8/20$$

$$\Rightarrow P(E \mid \text{diagnóstico} = \text{negative}) * P(\text{diagnóstico} = \text{negative})$$

$$\Rightarrow (2/8)(4/8)(6/8)(2/8)(8/8)(4/8)(7/8)(6/8)(8/20)$$

$$\Rightarrow \mathbf{0,003076}$$

Naive Bayes

□ Logo:

❖ Se $0,006287 > 0,003076$

❖ Então, há uma probabilidade maior de ser **positive**.

Naive Bayes

□ Logo:

- ❖ Se $0,006287 > 0,003076$
- ❖ Então, há uma probabilidade maior de ser **positive**.

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
High	High	High	Poor	Low	Obesity	Low_Risk	Adult	tested_positive



Naive Bayes

❑ Verossimilhança para as duas classes:

Para “**positive**”:

$$\Rightarrow (4/12) * (4/12) * (8/12) * (5/12) * (10/12) * (8/12) * (11/12) * (8/12) * (12/20) = 0,006287$$

Para “**negative**”:

$$\Rightarrow (2/8) * (4/8) * (6/8) * (2/8) * (8/8) * (4/8) * (7/8) * (6/8) * (8/20) = 0,003076$$

Naive Bayes

❑ Verossimilhança para as duas classes:

Para “**positive**”:

$$\Rightarrow (4/12) * (4/12) * (8/12) * (5/12) * (10/12) * (8/12) * (11/12) * (8/12) * (12/20) = 0,006287$$

Para “**negative**”:

$$\Rightarrow (2/8) * (4/8) * (6/8) * (2/8) * (8/8) * (4/8) * (7/8) * (6/8) * (8/20) = 0,003076$$

Convertendo para probabilidades por meio de normalização:

$$P(\text{"positive"}) = 0,006287 / (0,006287 + 0,003076) = 0,6714 \quad (67,1\%)$$

$$P(\text{"negative"}) = 0,003076 / (0,006287 + 0,003076) = 0,3285 \quad (32,8\%)$$

Naive Bayes

□ Pima Indians Diabetes Database (atributos numéricos):

#	Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
1	6	148	72	35	0	33,6	627	50	tested_positive
2	1	85	66	29	0	26,6	351	31	tested_negative
3	8	183	64	0	0	23,3	672	32	tested_positive
4	1	89	66	23	94	28,1	167	21	tested_negative
5	0	137	40	35	168	43,1	2288	33	tested_positive
6	5	116	74	0	0	25,6	201	30	tested_negative
7	3	78	50	32	88	31,0	248	26	tested_positive
8	10	115	0	0	0	35,3	134	29	tested_negative
9	2	197	70	45	543	30,5	158	53	tested_positive
10	4	110	92	0	0	37,6	191	30	tested_negative
11	10	168	74	0	0	38,0	537	34	tested_positive
12	10	139	80	0	0	27,1	1441	57	tested_negative
13	1	189	60	23	846	30,1	398	59	tested_positive
14	5	166	72	19	175	25,8	587	51	tested_positive
15	7	100	0	0	0	30,0	484	32	tested_positive
16	0	118	84	47	230	45,8	551	31	tested_positive
17	7	107	74	0	0	29,6	254	31	tested_positive
18	1	103	30	38	83	43,3	183	33	tested_negative
19	1	115	70	30	96	34,6	529	32	tested_positive
20	3	126	88	41	235	39,3	704	27	tested_negative

NB – Atributos Numéricos

- ❑ Suposição usual: os valores dos atributos têm uma **distribuição normal** ou Gaussiana (dada a classe).
- ❑ A função de densidade da probabilidade para a distribuição normal é definida por dois parâmetros:

❖ Média da amostra μ :

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

❖ Desvio padrão σ :

$$\sigma = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

Naive Bayes

□ Probabilidades para o Conjunto:

#	Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
1	6	148	72	35	0	33,6	627	50	tested_positive
3	8	183	64	0	0	23,3	672	32	tested_positive
5	0	137	40	35	168	43,1	2288	33	tested_positive
7	3	78	50	32	88	31,0	248	26	tested_positive
9	2	197	70	45	543	30,5	158	53	tested_positive
11	10	168	74	0	0	38,0	537	34	tested_positive
13	1	189	60	23	846	30,1	398	59	tested_positive
14	5	166	72	19	175	25,8	587	51	tested_positive
15	7	100	0	0	0	30,0	484	32	tested_positive
16	0	118	84	47	230	45,8	551	31	tested_positive
17	7	107	74	0	0	29,6	254	31	tested_positive
19	1	115	70	30	96	34,6	529	32	tested_positive
	4,17	142,17	60,83	22,17	178,83	32,95	611,08	38,67	
	3,43	38,87	22,49	18,09	262,07	6,60	552,56	11,14	

Naive Bayes

□ Probabilidades para o Conjunto:

#	Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
2	1	85	66	29	0	26,6	351	31	tested_negative
4	1	89	66	23	94	28,1	167	21	tested_negative
6	5	116	74	0	0	25,6	201	30	tested_negative
8	10	115	0	0	0	35,3	134	29	tested_negative
10	4	110	92	0	0	37,6	191	30	tested_negative
12	10	139	80	0	0	27,1	1441	57	tested_negative
18	1	103	30	38	83	43,3	183	33	tested_negative
20	3	126	88	41	235	39,3	704	27	tested_negative
	4,38	110,38	62,00	16,38	51,50	32,86	421,50	32,25	
	3,78	18,02	31,50	18,32	84,29	6,83	452,01	10,62	

Naive Bayes

□ Probabilidades para o Conjunto:

Pregnant			Plasma			BloodPressure			Skin		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
mean	4,17	4,38	mean	142,17	110,38	mean	60,83	62,00	mean	22,17	16,38
std dev	3,43	3,78	std dev	38,87	18,02	std dev	22,49	31,50	std dev	18,09	18,32
Insulin			BodyMass			Pedigree			Age		
-	Positive	Negative	-	Positive	Negative	-	Positive	Negative	-	Positive	Negative
mean	178,83	51,50	mean	32,95	32,86	mean	611,08	421,50	mean	38,67	32,25
std dev	262,07	84,29	std dev	6,60	6,83	std dev	552,56	452,01	std dev	11,14	10,62

Naive Bayes

□ Para uma nova instância:

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
7	103	66	32	0	39.1	344	31	?

Naive Bayes

□ Exemplo:

$$z(\textit{pregnant} = 7 \mid \textit{positive}) = \left| \frac{7 - \mu}{\sigma} \right| = 0,83$$

Naive Bayes


□ Exemplo:

$$z(\textit{pregnant} = 7 \mid \textit{positive}) = \left| \frac{7 - 4,17}{3,43} \right| = 0,83$$

Naive Bayes

□ Exemplo:


$$z(\text{pregnant} = 7 \mid \text{positive}) = \left| \frac{7 - 4,17}{3,43} \right| = 0,83$$



Naive Bayes

□ Exemplo:


$$z(\text{pregnant} = 7 \mid \text{positive}) = \left| \frac{7 - 4,17}{3,43} \right| = 0,83$$



Naive Bayes

□ Exemplo:

$$z(\text{pregnant} = 7 \mid \text{positive}) = \left| \frac{7 - 4,17}{3,43} \right| = 0,83$$




$$\begin{aligned} 7 - 0,5 &= 6,5 \\ 7 + 0,5 &= 7,5 \end{aligned}$$

Naive Bayes

□ Exemplo:

$$z(\text{pregnant} = 7 \mid \text{positive}) = \left| \frac{7 - 4,17}{3,43} \right| = 0,83$$



$$\begin{aligned} 7 - 0,5 &= 6,5 \\ 7 + 0,5 &= 7,5 \end{aligned}$$

Naive Bayes

□ Logo:

$$z' = \frac{|6,5 - 4,17|}{3,43} = 0,68$$

$$z'' = \frac{|7,5 - 4,17|}{3,43} = 0,97$$

Naive Bayes

□ Usando a Tabela da Distribuição Normal Reduzida:

$$z' = \frac{|6,5 - 4,17|}{3,43} = 0,68$$

$$z'' = \frac{|7,5 - 4,17|}{3,43} = 0,97$$

Z	0	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,0000	0,0040	0,0080	0,0120	0,0160	0,0199	0,0239	0,0279	0,0319	0,0359
0,1	0,0398	0,0438	0,0478	0,0517	0,0557	0,0596	0,0636	0,0675	0,0714	0,0753
0,2	0,0793	0,0832	0,0871	0,0910	0,0948	0,0987	0,1026	0,1064	0,1103	0,1141
0,3	0,1179	0,1217	0,1255	0,1293	0,1331	0,1368	0,1406	0,1443	0,1480	0,1517
0,4	0,1554	0,1591	0,1628	0,1664	0,1700	0,1736	0,1772	0,1808	0,1844	0,1879
0,5	0,1915	0,1950	0,1985	0,2019	0,2054	0,2088	0,2123	0,2157	0,2190	0,2224
0,6	0,2257	0,2291	0,2324	0,2357	0,2389	0,2422	0,2454	0,2486	0,2517	0,2549
0,7	0,2580	0,2611	0,2642	0,2673	0,2704	0,2734	0,2764	0,2794	0,2823	0,2852
0,8	0,2881	0,2910	0,2939	0,2967	0,2995	0,3023	0,3051	0,3078	0,3106	0,3133
0,9	0,3159	0,3186	0,3212	0,3238	0,3264	0,3289	0,3315	0,3340	0,3365	0,3389
1,0	0,3413	0,3438	0,3461	0,3485	0,3508	0,3531	0,3554	0,3577	0,3599	0,3621

Naive Bayes

❑ Usando a Tabela da Distribuição Normal Reduzida:

$$z' = \frac{|6,5 - 4,17|}{3,43} = 0,68$$

$$z'' = \frac{|7,5 - 4,17|}{3,43} = 0,97$$

Z	0	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,0000	0,0040	0,0080	0,0120	0,0160	0,0199	0,0239	0,0279	0,0319	0,0359
0,1	0,0398	0,0438	0,0478	0,0517	0,0557	0,0596	0,0636	0,0675	0,0714	0,0753
0,2	0,0793	0,0832	0,0871	0,0910	0,0948	0,0987	0,1026	0,1064	0,1103	0,1141
0,3	0,1179	0,1217	0,1255	0,1293	0,1331	0,1368	0,1406	0,1443	0,1480	0,1517
0,4	0,1554	0,1591	0,1628	0,1664	0,1700	0,1736	0,1772	0,1808	0,1844	0,1879
0,5	0,1915	0,1950	0,1985	0,2019	0,2054	0,2088	0,2123	0,2157	0,2190	0,2224
0,6	0,2257	0,2291	0,2324	0,2357	0,2389	0,2422	0,2454	0,2486	0,2517	0,2549
0,7	0,2580	0,2611	0,2642	0,2673	0,2704	0,2734	0,2764	0,2794	0,2823	0,2852
0,8	0,2881	0,2910	0,2939	0,2967	0,2995	0,3023	0,3051	0,3078	0,3106	0,3133
0,9	0,3159	0,3186	0,3212	0,3238	0,3264	0,3289	0,3315	0,3340	0,3365	0,3389
1,0	0,3413	0,3438	0,3461	0,3485	0,3508	0,3531	0,3554	0,3577	0,3599	0,3621

Naive Bayes

□ Finalizando:

$$z' = \frac{|6,5 - 4,17|}{3,43} = 0,68 \Rightarrow 0,2517$$

$$z'' = \frac{|7,5 - 4,17|}{3,43} = 0,97 \Rightarrow 0,3340$$

$$\therefore |0,3340 - 0,2517| = 0,0823$$

Naive Bayes

❑ Classificando uma nova instância:

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
7	103	66	32	0	39.1	344	31	?

Para “**positive**”:

$$\Rightarrow 0,0823 * 0,0072 * 0,0155 * 0,0172 * 0,0095 * 0,0387 * 0,0107 * 0,0219 = 0,0000000000000014$$

Para “**negative**”:

$$\Rightarrow 0,0844 * 0,0220 * 0,0119 * 0,0139 * 0,0067 * 0,0394 * 0,0078 * 0,0119 = 0,0000000000000008$$

Naive Bayes

❑ Classificando uma nova instância:

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
7	103	66	32	0	39.1	344	31	?

Para “**positive**”:

$$\Rightarrow 0,00000000000000014 / (0,00000000000000014 + 0,0000000000000008) =$$

$$\Rightarrow 0,643936434$$

$$\Rightarrow \mathbf{64,39\%}$$

Para “**negative**”:

$$\Rightarrow 0,00000000000000008 / (0,00000000000000014 + 0,0000000000000008) =$$

$$\Rightarrow 0,356063566$$

$$\Rightarrow \mathbf{35,61\%}$$

Naive Bayes

- Classificando uma nova instância:

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
7	103	66	32	0	39.1	344	31	tested_positive



Naive Bayes

❑ Observação:

- ❖ Valores **faltosos** durante treinamento não são incluídos no **cálculo da média** e do **desvio padrão**.

Overview

- ❑ Junto com árvores de decisão e vizinhos mais-próximos, é um dos métodos de aprendizagem mais práticos.
- ❑ Quando usá-lo:
 - ❖ Quando se tem disponível um conjunto de treinamento **médio** ou **grande**.
 - ❖ Os atributos que descrevem as instâncias forem **condicionalmente independentes**.

Dúvidas ...



Naive Bayes

❑ Qual será a classificação para essa nova instância?

Pregnant	Plasma	BloodPressure	Skin	Insulin	BodyMass	Pedigree	Age	Diagnóstico
5	88	66	21	23	24.4	342	30	?

Naive Bayes

Prática

Naive Bayes

- ❑ Parâmetros e valores default para Naive Bayes:

GaussianNB

```
class sklearn.naive_bayes.GaussianNB(*, priors=None,  
var_smoothing=1e-09)
```

[\[source\]](#)

Gaussian Naive Bayes (GaussianNB).

Can perform online updates to model parameters via `partial_fit`. For details on algorithm used to update feature means and variance online, see [Stanford CS tech report STAN-CS-79-773 by Chan, Golub, and LeVeque](#).

Read more in the [User Guide](#).

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html

Naive Bayes

❑ Parâmetros e valores default para Naive Bayes:

Parameters:

priors : *array-like of shape (n_classes,)*, *default=None*

Prior probabilities of the classes. If specified, the priors are not adjusted according to the data.

var_smoothing : *float, default=1e-9*

Portion of the largest variance of all features that is added to variances for calculation stability.

! *Added in version 0.20.*

https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html

Naive Bayes

❑ Utilizando GaussianNB (Holdout):

```
import pandas as pd

dataset = pd.read_csv('Diabetes.csv', encoding='utf-8')

## Selecionando todos os atributos com exceção da classe
X = dataset.iloc[:, :-1] # Features
y = dataset.classe       # Target variable (classe)

## Carregando o algoritmo
from sklearn.naive_bayes import GaussianNB
from sklearn.model_selection import train_test_split
from sklearn import metrics
from sklearn.metrics import confusion_matrix

# Separando dataset em duas partes: treinamento e teste
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=19)
```

Naive Bayes

❑ Utilizando GaussianNB (Holdout):

```
gnb = GaussianNB(priors = None, var_smoothing=1e-09)
gnb.fit(X_train, y_train)
y_pred = gnb.predict(X_test)
```

```
# Avaliando o modelo
print("Accuracy:", metrics.accuracy_score(y_test, y_pred))
print("Confusion Matrix:")
print(confusion_matrix(y_test, y_pred))
```

```
Accuracy: 0.7359307359307359
Confusion Matrix:
[[128  26]
 [ 35  42]]
```

Naive Bayes

❑ Utilizando GaussianNB (10 fold CV):

```
from sklearn.model_selection import KFold
from sklearn.model_selection import cross_val_score
from sklearn.model_selection import cross_val_predict
```

```
# 10-fold cv
```

```
kf = KFold(n_splits=10, random_state=1, shuffle=True)
```

```
gnb = GaussianNB(priors = None, var_smoothing=1e-09)
```

```
gnb.fit(X_train, y_train)
```

```
y_pred = gnb.predict(X_test)
```

```
# Model Accuracy
```

```
scores = cross_val_score(gnb, X, y, scoring='accuracy', cv=kf)
```

```
print('Accuracy: %.3f (%.3f)' % (scores.mean(), scores.std()))
```

```
# Matriz de confusão p/ k fold
```

```
y_pred = cross_val_predict(gnb, X, y, cv=kf)
```

```
confusion_matrix(y, y_pred)
```

```
Accuracy: 0.756 (0.054)
array([[419,  81],
       [106, 162]])
```

Obrigado!!!

