

UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE
INSTITUTO METROPOLE DIGITAL
IMD1101 - Aprendizado de Máquina – 2025.2
Prática de Comitês de Classificadores

Visando exercitar os conceitos aprendidos nas aulas de comitês de classificadores, o aluno deve implementar 4 métodos de comitês de classificadores, *Bagging*, *Random Forest*, *Voting* e *Stacking*.

BAGGING

Para essa estrutura de comitê de classificadores, utilize a técnica Bagging através da implementação `sklearn.ensemble.BaggingClassifier` para montar a tabela abaixo, no seguinte formato:

Bagging														
#	Base	Treinamento /Teste	k-NN (10)	k-NN (15)	k-NN (20)	DT (10)	DT (15)	DT (20)	NB (10)	NB (15)	NB (20)	MLP (10)	MLP (15)	MLP (20)
1	HOG_128_20x20 (900 atributos)	10-fold CV												
		70/30												
2	HOG_128_24x24 (576 atributos)	10-fold CV												
		70/30												
3	HOG_128_18x18 (1.296 atributos)	10-fold CV												
		70/30												
4	HOG_128_30x30 (324 atributos)	10-fold CV												
		70/30												
5	HOG_64_16x16 (324 atributos)	10-fold CV												
		70/30												
6	HOG_64_32x32 (36 atributos)	10-fold CV												
		70/30												
7	HOG_128_30x30 PCA- 75% (34 atributos)	10-fold CV												
		70/30												
8	HOG_128_32x32 (324 atributos)	10-fold CV												
		70/30												
9	HOG_256_32x32 (1764 atributos)	10-fold CV												
		70/30												
10	HOG_128_16x16 (1,764 atributos)	10-fold CV												
		70/30												
11	HOG_128_16x16 PCA- 75% (115 atributos)	10-fold CV												
		70/30												
12	LBP_256_6R (50 atributos)	10-fold CV												
		70/30												
#	Média =>		#DIV/0!	#DIV/0!	#####	#####	#####	#####	#####	#####	#####	#DIV/0!	#####	#DIV/0!
	Desv. Pad. =>		#DIV/0!	#DIV/0!	#####	#####	#####	#####	#####	#####	#####	#DIV/0!	#####	#DIV/0!

Figura 1 – Resultados do Bagging.

Parâmetros:

1. Fixar **estimator** para **KNeighborsClassifier** (melhor configuração);
2. Variar o atributo **n_estimators** para 10 (default), 20 e 30;
3. Para os demais parâmetros **max_samples** e **max_features**, deixe-os com seus valores default;
4. Preencher as demais colunas da tabela. Repetir os passos 1 a 3, variando o parâmetro **estimator** para, **DecisionTreeClassifier()**, **GaussianNB()** e **MLPClassifier()**.

Faça a análise de todos os modelos do Bagging para verificar se há diferença estatística entre eles. Havendo, escolha o melhor modelos de acordo com os testes estatísticos. Caso não haja, escolha o melhor modelo de acordo com a complexidade versos desempenho médio.

RANDOM FOREST

Para a segunda estrutura de comitês de classificadores, utilize a técnica Random Forest através da implementação `sklearn.ensemble.RandomForestClassifier` para montar a tabela abaixo, no seguinte formato:

Random Forest										
#	Base	Treinamento/ Teste	Gini (10)	Gini (20)	Gini (30)	Gini (100)	Entropy (10)	Entropy (20)	Entropy (30)	Entropy (100)
1	HOG_128_20x20 (900 atributos)	10-fold CV 70/30								
2	HOG_128_24x24 (576 atributos)	10-fold CV 70/30								
3	HOG_128_18x18 (1.296 atributos)	10-fold CV 70/30								
4	HOG_128_30x30 (324 atributos)	10-fold CV 70/30								
5	HOG_64_16x16 (324 atributos)	10-fold CV 70/30								
6	HOG_64_32x32 (36 atributos)	10-fold CV 70/30								
7	HOG_128_30x30 PCA- 75% (34 atributos)	10-fold CV 70/30								
8	HOG_128_32x32 (324 atributos)	10-fold CV 70/30								
9	HOG_256_32x32 (1764 atributos)	10-fold CV 70/30								
10	HOG_128_16x16 (1.764 atributos)	10-fold CV 70/30								
11	HOG_128_16x16 PCA- 75% (115 atributos)	10-fold CV 70/30								
12	LBP_256_6R (50 atributos)	10-fold CV 70/30								
#	Média =>		#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!
	Desv. Pad. =>		#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!

Figura 2 – Resultados do Random Forest.

Parâmetros:

1. Fixar **criterion** para **gini**;
2. Variar o atributo **n_estimators** para 10, 20, 30 e 100 (default);
3. Para os demais parâmetros, deixe-os no seus valores default;
4. Preencher as demais colunas da tabela. Repetir os passos 1 a 3, variando o parâmetro **criterion** para **entropy**.

Faça a análise de todos os modelos do Random Forest para verificar se há diferença estatística entre eles. Havendo, escolha o melhor modelos de acordo com os testes estatísticos. Caso não haja, escolha o melhor modelo de acordo com a complexidade versos desempenho médio.

STACKING

Para a terceira estrutura de comitês de classificadores, utilize a técnica *Stacking* através da implementação `sklearn.ensemble.StackingClassifier`. Para criar a tabela do *Stacking* heterogêneo, utilize tamanhos com 5, 10, 15 e 20 classificadores bases. Para os algoritmos de classificação, utilize MLP, k-NN, DT e NB.

Stacking						
#	Base	Treinamento/ Teste	Classificadores (5)	Classificadores (10)	Classificadores (15)	Classificadores (20)
1	HOG_128_20x20 (900 atributos)	10-fold CV 70/30				
2	HOG_128_24x24 (576 atributos)	10-fold CV 70/30				
3	HOG_128_18x18 (1.296 atributos)	10-fold CV 70/30				
4	HOG_128_30x30 (324 atributos)	10-fold CV 70/30				
5	HOG_64_16x16 (324 atributos)	10-fold CV 70/30				
6	HOG_64_32x32 (36 atributos)	10-fold CV 70/30				
7	HOG_128_30x30 PCA-75% (34 atributos)	10-fold CV 70/30				
8	HOG_128_32x32 (324 atributos)	10-fold CV 70/30				
9	HOG_256_32x32 (1764 atributos)	10-fold CV 70/30				
10	HOG_128_16x16 (1,764 atributos)	10-fold CV 70/30				
11	HOG_128_16x16 PCA-75% (115 atributos)	10-fold CV 70/30				
12	LBP_256_6R (50 atributos)	10-fold CV 70/30				
#	Média =>		#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!
	Desv. Pad. =>		#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!

Figura 3 – Resultados do Stacking.

Faça a análise de todos os modelos do Stacking para verificar se há diferença estatística entre eles. Havendo, escolha o melhor modelos de acordo com os testes estatísticos. Caso não haja, escolha o melhor modelo de acordo com a complexidade versus desempenho médio.

VOTING

Para esta estrutura de comitês de classificadores, utilize a técnica *Voting* através da implementação `sklearn.ensemble.VotingClassifier`. Para criar a tabela do *Voting* heterogêneo, utilize tamanhos com 5, 10, 15 e 20 classificadores bases. Para os algoritmos de classificação, utilize MLP, k-NN, DT e NB, evitando configurações complexas do MLP (que demandem muito tempo).

Voting						
#	Base	Treinamento/ Teste	Classificadores (5)	Classificadores (10)	Classificadores (15)	Classificadores (20)
1	HOG_128_20x20 (900 atributos)	10-fold CV 70/30				
2	HOG_128_24x24 (576 atributos)	10-fold CV 70/30				
3	HOG_128_18x18 (1.296 atributos)	10-fold CV 70/30				
4	HOG_128_30x30 (324 atributos)	10-fold CV 70/30				
5	HOG_64_16x16 (324 atributos)	10-fold CV 70/30				
6	HOG_64_32x32 (36 atributos)	10-fold CV 70/30				
7	HOG_128_30x30 PCA-75% (34 atributos)	10-fold CV 70/30				
8	HOG_128_32x32 (324 atributos)	10-fold CV 70/30				
9	HOG_256_32x32 (1764 atributos)	10-fold CV 70/30				
10	HOG_128_16x16 (1.764 atributos)	10-fold CV 70/30				
11	HOG_128_10x10 PCA-75% (115 atributos)	10-fold CV 70/30				
12	LBP_256_6R (50 atributos)	10-fold CV 70/30				
#	Média =>		#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!
#	Desv. Pad. =>		#DIV/0!	#DIV/0!	#DIV/0!	#DIV/0!

Figura 4 – Resultados do Voting.

Faça a análise de todos os modelos do Voting para verificar se há diferença estatística entre eles. Havendo, escolha o melhor modelos de acordo com os testes estatísticos. Caso não haja, escolha o melhor modelo de acordo com a complexidade versus desempenho médio.

Por último, faça uma análise dos melhores modelos escolhidos nas etapas anteriores (um modelo de cada estrutura de comitê), verificando se há se há diferença estatística entre eles. Havendo, escolha o melhor modelos de acordo com os testes estatísticos. Caso não haja, escolha o melhor modelo de acordo com a complexidade versus desempenho médio.

Bom trabalho!